Recomendador secuencial para H&M con Transformers — Entrega 1

Nov 3, 2026 · Valentina Romero, Matias Urrutia

1. Rubro, base y decisión

Rubro: moda online. **Base:** *H&M Personalized Fashion Recommendations* (Kaggle): 31,8 millones de compras con fecha, cliente, prenda, precio y canal, más un catálogo de 105.542 prendas con tipo, color, departamento y línea. **Usuaria:** una clienta de H&M online que acaba de comprar. **Decisión que apoya:** qué 10 prendas mostrarle en "Completa tu look" o en el correo de la semana.

Tras la limpieza quedan **579.226 interacciones, 36.168 clientas y 17.801 prendas** (mínimos: 50.000, 2.000 y 500), del 23-mar al 22-sep-2020.

2. Hallazgos

1. **Muy dispersa y con cola larga.** Densidad de 0,09 %. El 20 % de las prendas concentra el 60 % de las compras y 3 de cada 10 tienen menos de 10 compras.
2. **Se compra en carritos.** El 74 % de las compras consecutivas ocurre el mismo día. En el 70 % de las clientas, el ítem de validación y el de prueba son del mismo carrito; H&M no registra la hora.
3. **El orden importa.** Lo comprado el día anterior predice el último día un 64 % mejor que lo del primer día (HR@10 2,6 % vs 1,6 %). La compra siguiente es del mismo tipo de prenda 3,6 veces más que al azar, y ponderar las últimas compras sube el NDCG@10 de ítem–ítem en 28 %.
4. **La moda es temporal.** La popularidad de los últimos 3 días casi duplica a la de todo el período (HR@10 1,6 % vs 1,0 % en validación).
5. **Catálogo sesgado y variantes de color.** El 69 % de las compras es Ladieswear. Cada prenda existe en ≈ 2 colores, y los modelos de co-ocurrencia tienden a recomendar la misma prenda en otro color.

3. Decisiones

Limpieza. Últimos 6 meses y una muestra fija del 10 % de clientas (por hash), para entrenar en un computador normal. Varias unidades de la misma prenda el mismo día cuentan como una compra; las recompras en días distintos se conservan. Filtro 5-core más un mínimo de 2 días de compra por clienta. Secuencias ordenadas por fecha, con índices desde 1 (0 = relleno).

Protocolo. Leave-last-out igual para todos: último ítem = prueba, penúltimo = validación, resto = entrenamiento. Cada modelo ordena **las 17.801 prendas** (no una muestra de 100 negativos, como el repositorio SASRec.pytorch) y se excluye lo ya comprado. Métricas HitRate, NDCG y MRR en K = 5, 10 y 20, verificadas a mano en una clienta. Los hiperparámetros se eligen en validación y la prueba se mira una sola vez.

Modelos.

- **Popularidad:** global y reciente (ventana elegida en validación).

- **Reglas de asociación:** método del Certamen 2 (FP-Growth + `association_rules` de mlxtend, un consecuente, activación si el antecedente está en la canasta, orden por lift, relleno con los más vendidos).
- **Ítem–ítem coseno:** 100 vecinos por prenda, con peso λ^(L−j) que favorece las últimas compras.
- **SASRec:** implementación propia en PyTorch basada en SASRec.pytorch: embeddings de prenda y posición, atención causal con máscara triangular y bloques pre-norm con residual y feed-forward. Se entrena estilo GPT (predecir el ítem siguiente en cada posición) con **entropía cruzada sobre todo el catálogo**, porque optimiza lo mismo que se evalúa. La BCE con 1 negativo del repositorio queda como control. Se probaron 3 configuraciones más el control, con parada temprana por NDCG@10 de validación.

4. Resultados en prueba

SASRec tiene el mejor HitRate@10 y @20; ítem–ítem, el mejor NDCG y MRR. Prueba evaluada una sola vez, 36.168 clientas, ranking completo de 17.801 prendas.

Modelo	HR@5	HR@10	HR@20	NDCG@10	MRR	Cobertura@10	Entrenamiento	Parámetros
Popularidad global	0,34 %	0,87 %	1,48 %	0,004	0,004	0,1 %	0 s	17.801
Popularidad reciente (3 días)	0,88 %	1,65 %	2,96 %	0,008	0,009	2,8 %	0,1 s	3,3 M
Reglas de asociación (Certamen 2)	6,27 %	8,18 %	9,58 %	0,051	0,044	21,8 %	6 s	17.199 reglas
Ítem–ítem coseno (λ = 0,8)	**7,07 %**	8,72 %	10,35 %	**0,060**	**0,055**	**91,4 %**	1 s	1,7 M
SASRec (1 bloque, d = 64)	6,66 %	**8,95 %**	**11,73 %**	0,057	0,052	67,8 %	38 min	1,2 M

La inferencia cuesta lo mismo en todos (0,25 a 0,57 s por 1.000 clientas). En SASRec, la configuración de 1 bloque ganó en validación (NDCG@10 0,0507) a 2 bloques (0,0486) y a 2 bloques con d = 128 (0,0488). La misma arquitectura con la BCE de 1 negativo del repositorio llegó solo a 0,0187.

Por segmento (HR@10). En la **próxima visita** (otro día, 30 % de las clientas), SASRec logra 2,8 % contra 2,6 % de las reglas y 2,1 % de ítem–ítem. Al **completar el carrito** (mismo día), SASRec e ítem–ítem empatan en 11,6 %. En la **cola larga** gana ítem–ítem (5,6 % vs 4,6 %).

5. Costo-beneficio y conclusión

El Transformer vale la pena como complemento, no como reemplazo. Su ventaja global es pequeña (+0,23 puntos de HR@10 sobre ítem–ítem) y pierde en NDCG, MRR y cobertura. Además cuesta unas 2.000 veces más de entrenamiento: 38 minutos en CPU, o 1 h 45 min con la búsqueda de configuraciones, contra 1 segundo.

Lo que justifica su costo:

- **Próxima visita:** es el mejor modelo justo donde el orden entre días importa (+35 % sobre ítem–ítem), que es el caso del correo de la semana.
- **Interpretabilidad:** los pesos de atención muestran qué compra guía la recomendación. Una clienta que compró un blazer verde oscuro concentra ahí el 60 % de la atención y recibe primero la falda a juego, que efectivamente compró.
- **Estructura aprendida:** sin ver categorías, el 68,6 % de los 10 vecinos de cada prenda en el espacio de SASRec es de su mismo grupo de producto (21,1 % al azar). Trajes de baño, ropa interior y accesorios forman grupos separados.

La elección de la pérdida pesó más que la arquitectura: entropía cruzada sobre todo el catálogo rindió 2,7 veces más que la BCE con un negativo, mientras que un segundo bloque o más dimensiones no mejoraron.

Recomendación para H&M: un híbrido. Ítem–ítem para "Completa tu look" en el carrito y SASRec para el correo de la semana, con un re-ranking que limite las variantes de color de una misma prenda.

Limitaciones: H&M no registra la hora, así que el orden dentro de un mismo día es arbitrario. Se usó una muestra del 10 % de clientas y 6 meses de datos. Un 8 % de los ítems de prueba son recompras, que ningún modelo puede acertar porque se excluye lo ya comprado.

6. Plan de la Entrega 2

1. **Dashboard:** elegir una clienta y ver su historial con fotos, el top 10 de cada modelo lado a lado, los pesos de atención de SASRec y las métricas por segmento.
2. **Analista con IA:** un asistente que, a partir de los pesos de atención, las reglas activadas y los vecinos de ítem–ítem, explique por qué se recomienda cada prenda y la cuestione (por ejemplo, "3 de 5 sugerencias son la misma prenda en otro color").
3. **Innovación propuesta:** el híbrido por tipo de tarea (ítem–ítem en el carrito, SASRec en la próxima visita) con un re-ranking de diversidad que agrupe por `product_code`, medido con las mismas métricas más cobertura y diversidad.
4. **App publicada y exposición:** desplegar el dashboard en Streamlit, cargando `modelos/sasrec.pt` y los archivos de `data/`.