Recomendador secuencial para H&M con Transformers — Entrega 1

Nov 3, 2026 · @Mati

Integrantes: Valentina Romero y Matías Urrutia

1. Rubro, base y decisión

Rubro: moda online. **Base:** *H&M Personalized Fashion Recommendations* (Kaggle): 31,8 millones de compras con fecha, cliente, prenda y precio, y un catálogo de 105.542 prendas con atributos. **Usuaria:** clienta online que acaba de comprar. **Decisión:** qué 10 prendas mostrarle en "Completa tu look" o en el correo de la semana. Tras la limpieza quedan **579.226 interacciones, 36.168 clientas y 17.801 prendas** (23-mar a 22-sep-2020; mínimos: 50.000, 2.000 y 500).

2. Hallazgos

1. **Muy dispersa y con cola larga.** Densidad de 0,09 %. El 20 % de las prendas concentra el 60 % de las compras y 3 de cada 10 tienen menos de 10 compras.
2. **Se compra en carritos.** El 74 % de las compras consecutivas ocurre el mismo día. En el 70 % de las clientas, el ítem de validación y el de prueba son del mismo carrito; H&M no registra la hora.
3. **El orden importa.** El día anterior predice el último día un 64 % mejor que el primero (HR@10 2,6 % vs 1,6 %), la compra siguiente repite tipo de prenda 3,6 veces más que al azar y pesar más lo reciente sube 28 % el NDCG@10 de ítem–ítem.
4. **La moda es temporal.** La popularidad de los últimos 3 días casi duplica a la de todo el período (HR@10 1,6 % vs 1,0 % en validación).
5. **Catálogo sesgado y variantes de color.** El 69 % de las compras es Ladieswear. Cada prenda existe en ≈ 2 colores, y los modelos de co-ocurrencia tienden a recomendar la misma prenda en otro color.

3. Decisiones

Limpieza. Últimos 6 meses y una muestra fija del 10 % de clientas (por hash). Varias unidades de una prenda el mismo día cuentan como una compra; las recompras en otros días se conservan. Filtro 5-core más un mínimo de 2 días de compra por clienta; secuencias por fecha con índices desde 1 (0 = relleno).

Protocolo. Leave-last-out igual para todos (último ítem = prueba, penúltimo = validación, resto = entrenamiento). Cada modelo ordena **las 17.801 prendas** (no 100 negativos, como SASRec.pytorch) y se excluye lo ya comprado. HitRate, NDCG y MRR en K = 5, 10 y 20, verificadas a mano en una clienta. Hiperparámetros elegidos en validación; la prueba se mira una sola vez.

- **Popularidad:** global y reciente (ventana elegida en validación).
- **Reglas (Certamen 2):** FP-Growth + `association_rules` de mlxtend, un consecuente, activación si el antecedente está en la canasta, orden por lift y relleno con los más vendidos.
- **Ítem–ítem coseno:** 100 vecinos por prenda, con peso λ^(L−j) que favorece las últimas compras.
- **SASRec (PyTorch, basado en SASRec.pytorch):** embeddings de prenda y posición, atención causal (máscara triangular) y bloques pre-norm con residual y feed-forward, entrenado estilo GPT con **entropía cruzada sobre todo el catálogo**, que optimiza lo mismo que se evalúa. Tres configuraciones + BCE de 1 negativo como control; parada temprana por NDCG@10 de validación.

4. Resultados en prueba

SASRec tiene el mejor HitRate@10 y @20; ítem–ítem, el mejor NDCG y MRR (prueba evaluada una sola vez, 36.168 clientas).

Modelo	HR@10	HR@20	NDCG@10	MRR	Cobertura	Entrenamiento
Popularidad global	0,87 %	1,48 %	0,004	0,004	0,1 %	0 s
Popularidad reciente	1,65 %	2,96 %	0,008	0,009	2,8 %	0,1 s
Reglas (Certamen 2)	8,18 %	9,58 %	0,051	0,044	21,8 %	6 s
Ítem–ítem coseno	8,72 %	10,35 %	**0,060**	**0,055**	**91,4 %**	1 s
SASRec (1 bloque)	**8,95 %**	**11,73 %**	0,057	0,052	67,8 %	38 min

Por segmento (HR@10). En la **próxima visita** (otro día, 30 % de las clientas), SASRec logra 2,8 %, contra 2,6 % de las reglas y 2,1 % de ítem–ítem. Al **completar el carrito** empata con ítem–ítem (11,6 %), y en la **cola larga** gana ítem–ítem (5,6 % vs 4,6 %).

5. Costo-beneficio y conclusión

El Transformer vale la pena como complemento, no como reemplazo. Gana poco en HR@10 (+0,23 puntos sobre ítem–ítem), pierde en NDCG, MRR y cobertura, y entrena unas 2.000 veces más lento (38 min en CPU contra 1 s, con inferencia similar). Su costo se justifica por:

- **Próxima visita:** es el mejor justo donde importa el orden entre días (+35 % sobre ítem–ítem), que es el caso del correo semanal.
- **Interpretabilidad:** una clienta que compró un blazer verde oscuro concentra ahí el 60 % de la atención (α de la única cabeza del único bloque, en la fila de la última posición, la que puntúa el catálogo; suman 1 sobre su historial) y recibe primero la falda a juego, que efectivamente compró.
- **Estructura aprendida:** sin ver categorías, el 68,6 % de los 10 vecinos de cada prenda es de su mismo grupo de producto (21,1 % al azar).

La pérdida pesó más que la arquitectura: con la BCE de 1 negativo, el NDCG@10 de validación cae de 0,0507 a 0,0187; 2 bloques (0,0486) o d = 128 (0,0488) no ayudaron.

Recomendación para H&M: un híbrido. Ítem–ítem para "Completa tu look" en el carrito y SASRec para el correo de la semana, con un re-ranking que limite las variantes de color.

Limitaciones: sin hora de compra, el orden dentro del día es arbitrario; muestra del 10 % y 6 meses; el 8 % de la prueba son recompras, inalcanzables.

6. Plan de la Entrega 2

1. **Dashboard:** historial de la clienta, top 10 de SASRec y de las líneas base, pesos de atención y métricas.
2. **Analista con IA:** explica y cuestiona cada lista (atención, reglas, vecinos, sesgo a lo popular) sin reordenarla.
3. **Innovación:** híbrido por tipo de tarea con re-ranking de diversidad por `product_code`, medido con las mismas métricas más cobertura y diversidad.
4. **App:** Streamlit con `modelos/sasrec.pt` en CPU y la clave del LLM en `st.secrets`.